Sobreajuste - Overfitting

Miguel Cárdenas-Montes

Cuando se evalúa la calidad de un modelo o un ajuste, es importante medir el error en el conjunto de entrenamiento y en la predicción. La utilización exclusiva del error del conjunto de entrenamiento puede conducir a resultados engañosos. Estos errores pueden conducir a un fenómeno de sobreajuste (overfitting), en el cual el modelo se ajusta muy bien a los datos exitentes pero tiene un pobre rendimiento para predecir nuevos resultados.

Objetivos:

- Entender el problema del sobreajuste, y ponerlo en contexto con los errores de los modelos.

Este documento puede contener imprecisiones o errores. Por favor no lo utilice para citarlo como una fuente fiable.

En la imagen 1 se puede ver tres ajustes posibles a un conjunto de datos. En la gráfica de la izquierda, se observa como el modelo representado por una recta produce un ajuste pobre. Muchos puntos quedan alejados de la recta.

En la figura central, el modelo se ajusta a los puntos. La curva (modelo) para por muchos puntos pero no por todos. También se observa que este modelo debería precedir correctamente nuevos puntos incluso fuera del rango observado.

Finalmente en la figura de la derecha, se observa un modelo que pasa por casi todos los puntos. Este modelo debe dar el error (training error) más bajo de los tres modelos, por lo tanto debería ser el elegido como el mejos modelo. Sin embargo, este modelo no es bueno en la predicción de nuevos puntos.

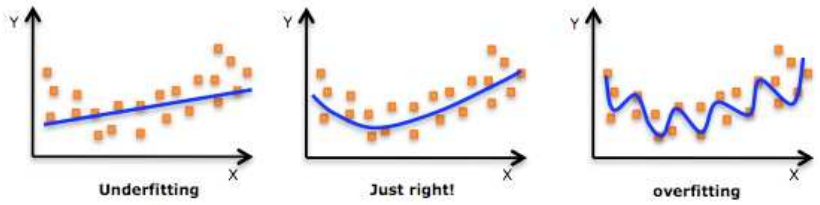

Figura 1: Tres modelos para un conjunto de puntos: a la izquierda un modelo con underfitting, en la figura central un modelo ajustado, y a la derecha un modelo con overfitting. Gráficas del curso *Machine Learning* de Andrew Ng.

También se puede interpretar las gráficas de la figura 1 en función del grado del polinomio del modelo, o la complejidad del modelo. Se puede entender que el modelo de la izquierda (recta) sea el modelo más simple, mientras que el modelo de la derecha es el más complejo (el polinomio tiene un grado más alto). En las siguientes gráficas se ampliará este estudio.

El ejemplo 2 es similar al anterior pero en vez de regresión, el ejemplo corresponde a un ejemplo de clasificación. La curva parabólica

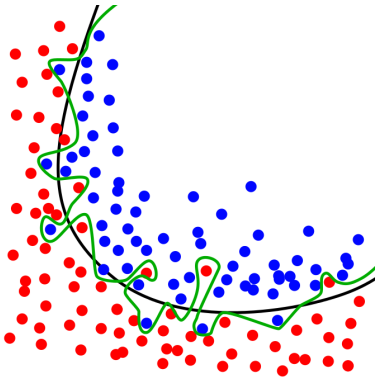

Figura 2: Ejemplo de clasificación ajustada (parábola) y con sobreajuste. Gráfica del curso *Machine Learning* de Andrew Ng.

corresponde a un modelo ajustado, y la línea quebrada corresponde con un modelo sobreajustado.

1 *Estudio Detallado en un Caso de Regresión*

En las figuras desde 3 a 7 se muestran ejemplos de regresión de diferentes órdenes: lineal (figura 3), cuadrática (figura 4), polinomio de cuarto orden (figura 5), sexto orden (figura 6), y décimo orden (figura 7).

El ajuste por un polinomio de orden lineal (figura 3) representa un caso de ajuste de baja calidad (sub-óptimo). Los datos no son bien representados por una recta. El valor mínimo obtenido por la función de coste es 0.631.

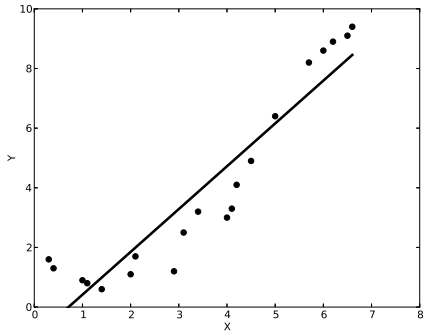

Figura 3: Ejemplo de ajuste lineal a un conjunto de datos, $h_\theta(x) = \theta_0 + \theta_1 \cdot x$. Como se puede apreciar es un caso de *underfitting*. El ajuste es de baja calidad. El valor de la función de coste es 0.631. Aparentemente los datos se ajustarían mejor si la hipótesis correspondiese a un polinomio de grado mayor.

El ajuste por un polinomio de orden cuadrático (figura 4) presenta un mejor ajuste a los datos, especialmente en comparación con el ajuste lineal. La curva se ajusta a los datos de manera que reduce el mínimo de la función de coste a 0.118.

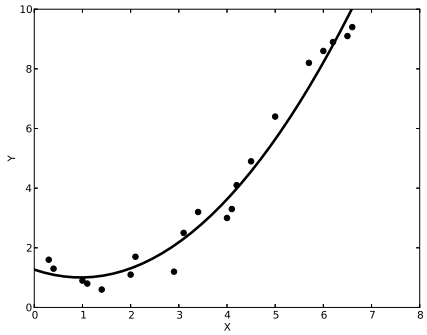

Figura 4: Ejemplo de ajuste cuadráticos sobre los mismos datos que en la figura 3. En este caso la hipótesis es $h_\theta(x) = \theta_0 + \theta_1 \cdot x + \theta_2 \cdot x^2$. En este caso el valor de la función de coste es 0.118. Visualmente el ajuste parece óptimo o cercano a él.

En las siguientes figuras se ajustan los datos sucesivamente por po-

linomios de orden cuarto (figura 5), sexto (figura 6) y décimo (figura 7). En todos estos casos hay una reducción continua del mínimo de la función de coste, siendo los valores correspondientes: 0.070, 0.052, y 0.047.

A medida que se incrementa el orden del polinomio, el mínimo de la función de coste disminuye constantemente. Es esperable que para un order muy alto, el polinomio pase por todos los puntos haciendo el valor de la función de coste nulo. La pregunta es si un polinomio de orden mayor supone una mejor representación de los datos, y lo que es crítico, una mayor capacidad para representar datos no incluidos previamente en el conjunto de entrenamiento.

Visualmente se intuye que los casos de orden sexto y décimo son mala representaciones de los datos, siempre y cuando el objetivo final sea obtener una función generalista del comportamiento que representan los datos.

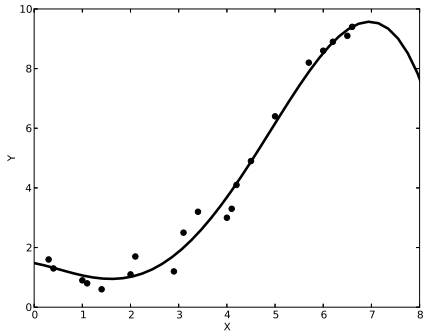

Figura 5: Ejemplo de ajuste con un polinomio de orden cuarto sobre los mismos datos que en la figura 3. En este caso la hipótesis es $h_\theta(x) = \theta_0 + \theta_1 \cdot x + \theta_2 \cdot x^2 + \theta_3 \cdot x^3 + \theta_4 \cdot x^4$. En este caso el valor de la función de coste es 0.070.

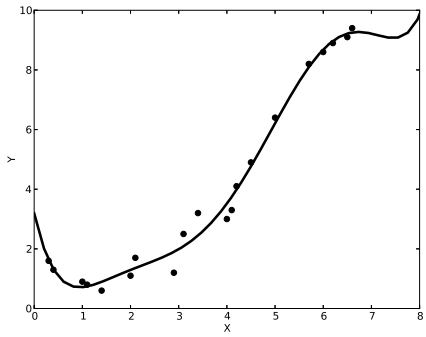

Figura 6: Ejemplo de ajuste con un polinomio de orden sexto sobre los mismos datos que en la figura 3. En este caso el valor de la función de coste es 0.052.

De esta forma, un caso típico de sobreajuste es el ajuste con el polinomio de orden décimo mostrado en la figura 7. En este caso, los valores de los parámetros θ_j son fuertemente dependientes de los datos particulares del conjunto de entrenamiento. Si se hubieran utilizado otro conjunto de datos, los parámetros θ_j serían muy diferentes de

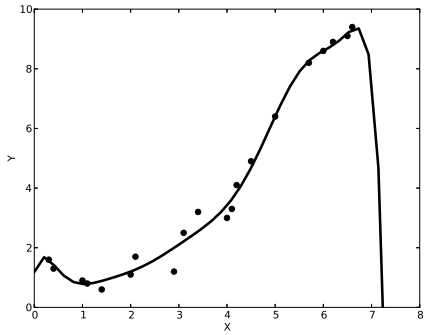

Figura 7: Ejemplo de ajuste con un polinomio de orden décimo sobre los mismos datos que en la figura 3. En este caso el valor de la función de coste es 0.047.

los obtenidos. De ahí que se haya sobreajustado los parámetros a los datos.

Por lo tanto queda por resolver cómo obtener un buen ajuste para el conjunto de datos de entrenamiento (ajuste de los parámetros del modelo), y a su vez que sea generalista del comportamiento del fenómeno representado (ajuste de la complejidad del modelo).

Para resolver esta cuestión se utiliza el error de validación (*crossvalidation*). En este caso, se divide el conjunto de datos originales, apartando un pequeño subgrupo de los mismos. Una vez realizado el ajuste, se utilizan los parámetros θ_j obtenidos para hayar el valor estimado de la salida de estos datos. En la figura se muestra el conjuntos de datos de entrenamiento (puntos) y el conjunto de datos para la validación del modelo.

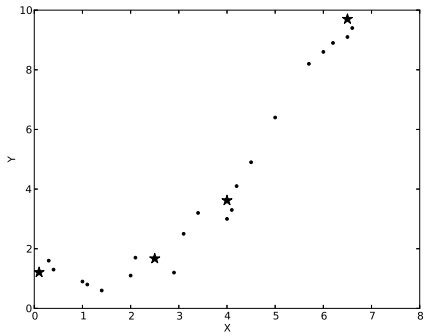

Figura 8: Datos originales más 4 datos adicionales (estrellas) para realizar la validación del modelo.

En la tabla 1 se muestra el valor del error de la validación para cada modelo. Como puede observarse este valor es mínimo para el modelo cuadrático.

Por lo tanto, el objetivo del ajuste debería de ser el modelo que mejor ajuste (más bajo error) con la menor complejidad posible.

El conjunto de entrenamiento se utilizar para encontra los valores óptimos del los parámetros del modelo, y el conjunto de validación se utilizar para encontrar el modelo de mejor complejidad.

Orden	Error de Validación
Lineal	12.69236
Cuadrático	0.00005
Cuarto	0.04356
Sexto	0.05084
Décimo	0.05705

Cuadro 1: Valores del error de validación.

2 *El Peligro del Sobreajuste*

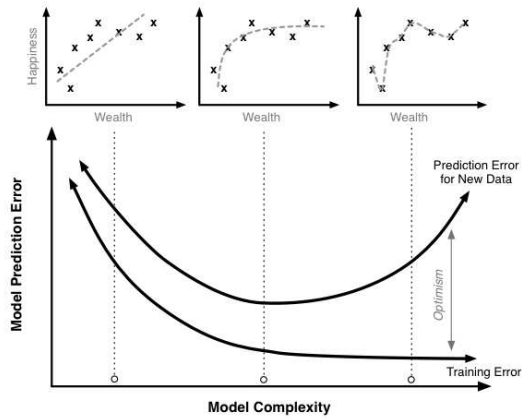

Figura 9: Ejemplo de ajuste a un conjunto de punto, y sus errores asociados a medida que aumenta la complejidad del modelo.

La figura 9 muestra la relación existente entre el error de entrenamiento y la complejidad del modelo. En las imagenes superiores, se ve el ajuste de un conjunto de puntos a un modelo lineal, polinomial de bajo grado y polinomial de alto grado.

Al incrementar la complejidad del modelo siempre decrece el error de training. Para niveles muy altos de complejidad, el modelo debería predecir perfectamente todos los puntos del conjunto de entrenamiento. El error de entrenamiento debería ser nulo.

Si se analiza la capacidad de predicción de nuevos puntos, el modelo de baja complejidad debe tener una pobre capacidad de predicción (alto valor del error de predicción). A medida que aumente la complejidad del modelo, el error de predicción bajará. Sin embargo, para modelos de alta complejidad el error de predicción volverá al ser alto. Este modelo de alta complejidad será pobre en la predicción de nuevos puntos fuera del conjunto de entrenamiento. La prevención del sobreajuste es esencial para la construcción de modelos precisos y robustos.

La técnica denominada *regularización* permite reducir el riesgo de sobreajuste.